

Пошуковий аналіз даних

Ознайомитись з методами перевірки статистичних гіпотез. Після завершення цієї лабораторної роботи ви зможете:

- Досліджувати дані за допомогою візуалізацій
 - Робити описовий аналіз
 - Групувати дані для аналізу
 - Знаходити зв'язок між ознаками
 - Перевіряти гіпотези про значущість коефіцієнта кореляції та про вигляд закону розподілу
 - Робити дисперсійний аналіз
1. Скачати дані із файлу, який зберегли наприкінці попередньої роботи (з виправленими помилками та заповненими пропусками). Записати дані у dataframe. Дослідити ознаки з метою виявлення зв'язку між ними, побудувавши їх візуалізації. Візуально оцініть наявність та силу зв'язку між ознаками.
 2. Порахувати кореляцію між всіма кількісними ознаками
 3. Побудувати діаграми розсіювання для кількісних ознак та 'CO2 emission'. Які кількісні ознаки можуть бути предикторами кількості викидів CO2?
 4. Побудувати діаграму розмаху для 'CO2 emission' по регіонам.
 5. Виконати дисперсійний аналіз для кількості викидів CO2, згрупувати дані по регіонам

Завдання #1:

Зчитую дані з файлу у датафрейм

```
# Напишіть ваш код нижче та натисніть Shift+Enter для виконання
import pandas as pd
DATA_PATH = 'clean_data.csv'
df = pd.read_csv(DATA_PATH, sep=',', index_col=0)
df.head()
```

	Country Name	Region	GDP per capita
Population \			
0	Afghanistan	South Asia	561.778746
34656032.0			
1	Albania	Europe & Central Asia	4124.982390
2876101.0			
2	Algeria	Middle East & North Africa	3916.881571
40606052.0			
3	American Samoa	East Asia & Pacific	11834.745230
55599.0			
4	Andorra	Europe & Central Asia	36988.622030


77281.0

	C02 emission	Area	Population density
0	9809.225	652860	53.083405
1	5716.853	28750	100.038296
2	145400.217	2381740	17.048902
3	6501.591	200	277.995000
4	462.042	470	164.427660

Будую діаграми

```
# Напишіть ваш код нижче та натисніть Shift+Enter для виконання
import seaborn as sns
sns.pairplot(df, diag_kind='kde', kind='reg')

<seaborn.axisgrid.PairGrid at 0x7f8699ae9a90>
```



Найбільш виражений позитивний зв'язок спостерігається між Population і CO2 emission — точки чітко тягнуться вздовж лінії тренду вгору, що підтверджує сильну кореляцію. Подібний але слабший зв'язок видно між Area і CO2 emission — лінія тренду має помітний нахил але точки розкидані ширше. Зв'язок GDP per capita з CO2 emission візуально майже непомітний — лінія тренду практично горизонтальна, точки хаотично розкидані. Population density не показує жодного зв'язку з іншими ознаками. По діагоналі видно що всі ознаки мають правосторонню асиметрію — більшість країн зосереджена біля малих значень з довгим хвостом вправо, що свідчить про ненормальний розподіл даних.


Візуально оцінію наявність та силу зв'язку між ознаками.

Завдання #2:

Рахую кореляцію між всіма кількісними ознаками

```
# Напишіть ваш код нижче та натисніть Shift+Enter для виконання
numeric_df = df.select_dtypes(include=['float64', 'int64'])
sns.heatmap(numeric_df.corr(), annot=True)
```

<Axes: >




Кореляційна матриця показує що найсильніший зв'язок з CO2 emission має Population ($r = 0.80$) — сильна позитивна кореляція, та Area ($r = 0.59$) — помірна позитивна кореляція. Також варто відзначити сильний зв'язок між самими Population та Area ($r = 0.45$) — більші за площею країни як правило мають більше населення. GDP per capita ($r = 0.088$) та Population density ($r = -0.024$) практично не корелюють з CO2 emission. Негативна кореляція Population density з Area ($r = -0.064$) є логічною — чим більша площа країни, тим менша густина населення.

Завдання #3:

Будую діаграму розсіювання для кількісних ознак та 'CO2 emission'

```
# Напишіть ваш код нижче та натисніть Shift+Enter для виконання
numeric_df = df.select_dtypes(include=['float64', 'int64'])
sns.pairplot(numeric_df, x_vars=numeric_df.drop(columns=['CO2 emission']), y_vars=['CO2 emission'], kind='reg')

<seaborn.axisgrid.PairGrid at 0x7f86a1fb2d70>
```



```
# Напишіть ваш код нижче та натисніть Shift+Enter для виконання
from scipy import stats
for col in numeric_df.columns:
    if col == 'CO2 emission':
        continue
    r, p = stats.pearsonr(numeric_df[col], numeric_df['CO2 emission'])
    print(f"{col:<25} PearsonR = {r:+.5f} P value = {p:.5g}")
```

GDP per capita	PearsonR = +0.08843	P value = 0.19442
Population	PearsonR = +0.80410	P value = 1.862e-50
Area	PearsonR = +0.58830	P value = 1.3467e-21
Population density	PearsonR = -0.02390	P value = 0.72629

Виходячи з результатів маємо:

Population — $r = +0.80$, $p \approx 0 \rightarrow$ сильний зв'язок, статистично значимий. Чим більше населення, тим більше викидів CO2. Найкращий предиктор.

Area — $r = +0.59$, $p \approx 0 \rightarrow$ помірний зв'язок, статистично значимий. Більші за площею країни викидають більше CO2.

GDP per capita — $r = +0.09$, $p = 0.19 \rightarrow$ зв'язок слабкий і незначимий ($p > 0.05$). Не можна вважати предиктором.

Population density — $r = -0.02$, $p = 0.73 \rightarrow$ зв'язку практично немає, незначимий. Не предиктор.

Кількісні ознаки, які можуть бути предикторами кількості викидів CO2: Population та Area, оскільки вони мають статистично значиму кореляцію з CO2 emission ($p < 0.05$).

Завдання #4:


Напишіть ваш код нижче та натисніть Shift+Enter для виконання

```
import matplotlib.pyplot as plt
regions = df['Region'].unique()
colors = sns.color_palette("bright")
rows = (len(regions) + 3) // 4

fig, axes = plt.subplots(nrows=rows, ncols=4, figsize=(18, 6 * rows),
                        tight_layout=True)
axes = axes.flatten()

for i, region in enumerate(regions):
    sns.boxplot(data=df[df['Region'] == region], x='Region', y='CO2
emission', ax=axes[i], color=colors[i])

for j in range(len(regions), len(axes)):
    axes[j].axis('off')
```



Діаграми розмаху по регіонах показують суттєві відмінності у рівні викидів CO2. North America має найбільший медіанний рівень викидів та найширший розмах, що свідчить про великий розкид між країнами регіону. Middle East & North Africa також демонструє відносно високі значення з великим розмахом ящика. Натомість Sub-Saharan Africa та South Asia

мають найнижчі медіанні значення і ящики стиснуті до нуля. У всіх регіонах присутні значні викиди (outliers) — це країни-гіганти які сильно відрізняються від решти у своєму регіоні, що додатково підтверджує ненормальний розподіл даних.

Завдання #5:

Групую дані, щоб побачити чи впливає 'Region' на 'CO2 emission'.

```
groups = [group['CO2 emission'].values
           for _, group in df.groupby('Region')]
```

Перевіряю розподіл даних в групах, щоб обрати вид дисперсійного аналізу.

```
# Напишіть ваш код нижче та натисніть Shift+Enter для виконання

#Perform the Shapiro-Wilk test for normality.
#The Shapiro-Wilk test tests the null hypothesis that the data was
drawn from a normal distribution.
for region, group in df.groupby('Region'):
    stat, p = stats.shapiro(group['CO2 emission'])
    normal = True if p > 0.05 else False
    print(f"{region:<35} p = {p:.5g} -> {'normal' if normal else
'not normal'}")

East Asia & Pacific          p = 9.3025e-13 -> not normal
Europe & Central Asia       p = 1.2528e-13 -> not normal
Latin America & Caribbean   p = 1.8994e-11 -> not normal
Middle East & North Africa  p = 5.5771e-06 -> not normal
North America               p = 0.17752 -> normal
South Asia                  p = 4.8379e-06 -> not normal
Sub-Saharan Africa          p = 1.3857e-14 -> not normal
```

Для отримання F-test score та P-value скористаюсь функцією `f_oneway` з модуля "stats", якщо розподіл даних в групах дозволяє застосувати класичний дисперсійний аналіз, або `kruskal` з модуля "stats" для непараметричного дисперсійного аналізу Краскела-Уоліса.

```
# Напишіть ваш код нижче та натисніть Shift+Enter для виконання
if normal:
    stat, p = stats.f_oneway(*groups)
    test_name = 'F'
else:
    stat, p = stats.kruskal(*groups)
    test_name = 'H'

print(f"{test_name}-statistic = {stat:.5f}, p-value = {p:.5g}")

H-statistic = 44.68739, p-value = 5.3996e-08
```

Результат із $H = 44.68739$ показником тесту і $p\text{-value} = 5.3996e-08$ показує, що між регіонами є статистично значима різниця у викидах CO2. Але чи означає це, що досліджувані групи значуще відрізняються між собою?

Розглянемо їх окремо.

```
from itertools import combinations
import numpy as np

regions = df['Region'].unique()
n = len(regions)

# створюємо матрицю p-values
p_matrix = pd.DataFrame(np.ones((n, n)), index=regions,
                        columns=regions)

for r1, r2 in combinations(regions, 2):
    g1 = df[df['Region'] == r1]['CO2 emission']
    g2 = df[df['Region'] == r2]['CO2 emission']
    _, p = stats.mannwhitneyu(g1, g2)
    p_matrix.loc[r1, r2] = p
    p_matrix.loc[r2, r1] = p

# форматуємо анотації
annot_matrix = p_matrix.map(lambda x: f'{x:.3f}' if x >= 0.001 else
                             f'{x:.2e}')

# будуємо heatmap
fig, ax = plt.subplots(figsize=(10, 8))
sns.heatmap(
    p_matrix,
    annot=annot_matrix, fmt='',
    cmap='RdYlGn',
    vmin=0, vmax=0.1,
    linewidths=0.5, ax=ax
)
ax.set_title('Матриця P-values для попарного порівняння регіонів',
             pad=12)
plt.xticks(rotation=45, ha='right')
plt.tight_layout()
plt.show()
```




Попарне порівняння регіонів методом Манна-Уїтні показало, що найбільша різниця у викидах CO2 спостерігається між Europe & Central Asia та Sub-Saharan Africa ($p = 1.01e-08$). Також значимо відрізняються Middle East & North Africa і Sub-Saharan Africa ($p = 1.64e-07$), та Latin America & Caribbean і Europe & Central Asia ($p = 2.63e-04$). Натомість такі регіони як North America та більшість інших регіонів не показали статистично значимої різниці між собою ($p > 0.05$), що може пояснюватись малою кількістю країн у цих групах або великим розкидом даних всередині груп.

Додаткове завдання:

1. По результатам дисперсійного аналізу для кількості викидів CO2 по регіонам, вкажіть пару регіонів, що відрізняються найсильніше.
2. Створіть якісну ознаку 'Rich country', згрупувавши дані 'GDP per capita' в кілька категорій (багаті-бідні країни, 3-5 категорій). Побудуйте діаграму розмаху для 'CO2 emission' по категоріям 'Rich country'. Візуально оцініть наявність зв'язку між цими ознаками.

3. Виконайте дисперсійний аналіз для 'CO2 emission', згрупувавши дані по категоріям 'Rich country'.

```
# Напишіть ваш код нижче та натисніть Shift+Enter для виконання
min_p = 1.0
pair = ('', '')

for r1, r2 in combinations(regions, 2):
    p = p_matrix.loc[r1, r2]
    if p < min_p:
        min_p = p
        pair = (r1, r2)

print(f"Найбільша різниця між: {pair[0]} та {pair[1]}")
print(f"p-value = {min_p:.2e}")

Найбільша різниця між: Europe & Central Asia та Sub-Saharan Africa
p-value = 1.01e-08

# створюємо категорії по GDP per capita
bins = [0, 1000, 5000, 15000, 40000, float('inf')]
labels = ['Дуже бідні', 'Бідні', 'Середні', 'Багаті', 'Дуже багаті']

df['Rich country'] = pd.cut(df['GDP per capita'], bins=bins,
labels=labels)


# діаграма розмаху
fig, ax = plt.subplots(figsize=(10, 6))

order = ['Дуже бідні', 'Бідні', 'Середні', 'Багаті', 'Дуже багаті']
sns.boxplot(data=df, x='Rich country', y='CO2 emission',
            order=order, ax=ax)

plt.ylim(0, 25e5)

ax.set_title('CO2 emission по категоріях багатства країн',
            fontsize=13)
ax.set_xlabel('Категорія країни', fontsize=11)
ax.set_ylabel('CO2 emission', fontsize=11)

Text(0, 0.5, 'CO2 emission')
```



Діаграма розмаху демонструє чіткий висхідний тренд - медіана CO2 emission зростає від категорії "Дуже бідні" до "Дуже багаті". Це свідчить про наявність позитивного зв'язку між рівнем ВВП на душу населення та викидами CO2 - багатші країни в цілому викидають більше. Водночас у кожній категорії присутні значні викиди, що вказує на великий розкид всередині груп.

```
# групуємо
groups = [group['CO2 emission'].values
           for _, group in df.groupby('Rich country')]

# перевірка нормальності
all_normal = True
for name, group in df.groupby('Rich country'):
    stat, p = stats.shapiro(group['CO2 emission'])
    is_normal = p > 0.05
    label = 'нормальний' if is_normal else 'НЕ нормальний'
    print(f"{name:<15} p = {p:.5g} → {label}")
    if not is_normal:
        all_normal = False

# обираємо тест
if all_normal:
    stat, p = stats.f_oneway(*groups)
    test_name = 'F'
else:
```

```

stat, p = stats.kruskal(*groups)
test_name = 'H'

print(f"\n{test_name}-statistic = {stat:.5f}, p-value = {p:.5g}\n")

# статистика по групах
summary = df.groupby('Rich country')['CO2 emission'].agg(
    Кількість='count',
    Середнє='mean',
    Медіана='median',
).round(2)
print(summary)

```

Дуже бідні	p = 1.0642e-05	→ НЕ нормальний
Бідні	p = 4.7499e-17	→ НЕ нормальний
Середні	p = 2.4729e-17	→ НЕ нормальний
Багаті	p = 3.503e-08	→ НЕ нормальний
Дуже багаті	p = 5.5413e-09	→ НЕ нормальний

H-statistic = 30.18490, p-value = 4.488e-06

	Кількість	Середнє	Медіана
Rich country			
Дуже бідні	31	4172.81	2449.56
Бідні	68	71418.65	9229.84
Середні	66	257117.54	10819.48
Багаті	30	135448.47	31008.15
Дуже багаті	22	368839.19	47463.81

За результатами перевірки нормальності розподіл CO2 emission є ненормальним у всіх категоріях ($p < 0.05$), тому застосовано непараметричний тест Краскела-Уоліса. Результат $H = 30.18$, $p\text{-value} = 4.49\text{e-}06$ вказує на статистично значиму різницю у викидах CO2 між категоріями країн за рівнем ВВП. Середні та медіанні значення зростають від "Дуже бідних" (медіана 2449) до "Дуже багатих" (медіана 47463), що підтверджує що рівень багатства країни є значимим фактором впливу на кількість викидів CO2.