

Побудова моделі

Ознайомитись з різновидами регресійних моделей. Після завершення цієї лабораторної роботи ви зможете:

- Будувати регресійні моделі кількох видів
 - Оцінювати якість моделі візуально
 - Оцінювати якість моделі за допомогою числових мір, без використання тестової вибірки
 - Виконувати прогнозування відгуку, використовуючи побудовану модель
1. Скачати дані з фінального файлу першої роботи з виправленими помилками та заповненими пропусками. Записати дані у dataframe. В попередній роботі ви визначили ознаки, що можуть бути предикторами для 'CO2 emission'. Побудуйте моделі лінійної регресії для кожного з цих предикторів.
 2. Побудуйте модель множинної лінійної регресії для всіх доречних предикторів разом.
 3. Побудуйте кілька поліноміальних моделей другого порядку.
 4. Побудуйте візуалізації для оцінки всіх моделей.
 5. Порахуйте значення R^2 та MSE для оцінки якості кожної моделі. Оберіть найкращу модель.

Завдання #1:

Зчитую дані з файлу у датафрейм

```
# Напишіть ваш код нижче та натисніть Shift+Enter для виконання
import pandas as pd
df = pd.read_csv('clean_data.csv', index_col=0)
df.head()
```

	Country Name	Region	GDP per capita
Population \			
0	Afghanistan	South Asia	561.778746
34656032.0			
1	Albania	Europe & Central Asia	4124.982390
2876101.0			
2	Algeria	Middle East & North Africa	3916.881571
40606052.0			
3	American Samoa	East Asia & Pacific	11834.745230
55599.0			
4	Andorra	Europe & Central Asia	36988.622030
77281.0			
	CO2 emission	Area	Population density
0	9809.225	652860	53.083405

1	5716.853	28750	100.038296
2	145400.217	2381740	17.048902
3	6501.591	200	277.995000
4	462.042	470	164.427660

Розробимо моделі, використовуючи ці ознаки як змінні-предиктори.

```
# Напишіть ваш код нижче та натисніть Shift+Enter для виконання
from sklearn.linear_model import LinearRegression
x1 = df[['Population']]
y1 = df[['CO2 emission']]
lm1= LinearRegression()
lm1.fit(x1, y1)

LinearRegression()
```

Знаходжу коефіцієнти моделі

```
# Напишіть ваш код нижче та натисніть Shift+Enter для виконання
print(lm1.intercept_)
print(lm1.coef_)

[-8404.37142621]
[[0.00484808]]
```

Отримали кінцеву лінійну модель зі структурою:

$$\hat{Y} = a + bX$$

Підставляючи фактичні значення, маємо:

```
# Напишіть рівняння моделі, виконувати не потрібно

#  $\hat{Y} = -8404.37 + 0.0048 * Population$ 
```

Створюю об'єкт лінійної регресії та навчаю другу модель

```
# Напишіть ваш код нижче та натисніть Shift+Enter для виконання
x2 = df[['Area']]
y2 = df[['CO2 emission']]
lm2= LinearRegression()
lm2.fit(x2, y2)

LinearRegression()
```

Знаходжу коефіцієнти моделі

```
# Напишіть ваш код нижче та натисніть Shift+Enter для виконання
print(lm2.intercept_)
print(lm2.coef_)

[-4181.76061729]
[[0.26093456]]
```

Отримали кінцеву лінійну модель зі структурою:

$$\hat{Y}_2 = a + b X$$

Підставляючи фактичні значення, маємо:

```
# Напишіть рівняння моделі, виконувати не потрібно
#  $\hat{Y}_2 = -4181.76 + 0.261 * Area$ 
```

Завдання #2:

Створюю об'єкт лінійної регресії та навчаю множинну лінійну модель із структурою

$$\hat{Y}_3 = a + b_1 X_1 + b_2 X_2$$

```
# Напишіть ваш код нижче та натисніть Shift+Enter для виконання
x3 = df[['Population', 'Area']]
y3 = df[['CO2 emission']]
lm3= LinearRegression()
lm3.fit(x3, y3)

LinearRegression()
```

Знаходжу коефіцієнти моделі

```
# Напишіть ваш код нижче та натисніть Shift+Enter для виконання
print(lm3.intercept_)
print(lm3.coef_)

[-59329.0476349]
[[0.00407831 0.12480348]]
```

Підставляючи фактичні значення, маємо:

```
# Напишіть рівняння моделі, виконувати не потрібно
#  $\hat{Y}_3 = -59329.0476 + 0.0041 * Population + 0.1248 * Area$ 
```

Завдання #3:

Створюю об'єкт поліноміальної регресії та навчаю поліноміальну модель із структурою

$$\hat{Y}_4 = a + b_1 X_1 + b_2 X_1^2$$

Знаходжу коефіцієнти моделі

```
# Напишіть ваш код нижче та натисніть Shift+Enter для виконання
import numpy as np
x4 = df['Population']
y4 = df['CO2 emission']
f4 = np.polyfit(x4, y4, 2)
p4 = np.polyld(f4)
print(p4)
```

$$-3.846e-13 x^2 + 0.00533 x - 1.751e+04$$

Створюю об'єкт поліноміальної регресії та навчаю поліноміальну модель із структурою

$$\hat{Y}_5 = a + b_1 X_2 + b_2 X_2^2$$

Знаходжу коефіцієнти моделі

```
# Напишіть ваш код нижче та натисніть Shift+Enter для виконання
x5 = df['Area']
y5 = df['CO2 emission']
f5 = np.polyfit(x5, y5, 2)
p5 = np.polyld(f5)
print(p5)
```

$$-1.52e-08 x^2 + 0.4416 x - 5.963e+04$$

Створюю об'єкт поліноміальної регресії та навчаю поліноміальну модель із структурою

$$\hat{Y}_6 = a + b_1 X_1 + b_2 X_2 + b_3 X_1 X_2 + b_4 X_1^2 + b_5 X_2^2$$

Знаходжу коефіцієнти моделі

```
# Напишіть ваш код нижче та натисніть Shift+Enter для виконання
from sklearn.preprocessing import PolynomialFeatures
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler

Input6 = [('scale', StandardScaler()), ('polynomial',
PolynomialFeatures(include_bias=False)), ('model', LinearRegression())]
pipe6 = Pipeline(Input6)
```

```

x6 = df[['Population', 'Area']]
y6 = df['CO2 emission']
pipe6.fit(x6, y6)

print("Coefficients: ", pipe6.named_steps['model'].coef_)
print("Intercept: ", pipe6.named_steps['model'].intercept_)

Coefficients: [372027.92569179 100774.52692872 -57060.27663041
249173.33869438
-14520.16819742]
Intercept: 115818.22092601999

```

Завдання #4:

Для простої лінійної регресії чудовим способом візуалізації відповідності моделі є використання графіків регресії. Цей графік покаже комбінацію розсіяних точок даних (діаграма розсіювання, scatterplot) та підігнану лінію лінійної регресії, що проходить через дані.

Таким способом візуалізую перші моделі.

```


import seaborn as sns
import matplotlib.pyplot as plt
%matplotlib inline


width = 12
height = 10
plt.figure(figsize=(width, height))
sns.regplot(x=x1, y=y1, data=df)
plt.ylim(0,)

plt.figure(figsize=(width, height))
sns.regplot(x=x2, y=y2, data=df)
plt.ylim(0,)

(0.0, 10954417.688156724)

```






Для візуалізації дисперсії даних використаю діаграми залишків - по ній зможу прийняти рішення про необхідність ускладнення моделі.


Напишіть ваш код нижче та натисніть Shift+Enter для виконання

```
plt.figure(figsize=(width, height))
sns.residplot(x=x1, y=y1, data=df)
```

```
plt.figure(figsize=(width, height))
sns.residplot(x=x2, y=y2, data=df)
```

```
<Axes: xlabel='Area', ylabel='CO2 emission'>
```





Первинний аналіз за допомогою простої лінійної регресії виявив суттєві недоліки моделі. На графіках залишків чітко видно, що похибка прогнозу для невеликих країн є мінімальною, проте зі зростанням населення та площі розкид помилок критично збільшується. Крім того, наявність вираженої структури (вигину) у залишках свідчить про те, що лінійна залежність від одного фактора не здатна адекватно описати викиди для країн-гігантів.

Для візуалізації моделі множинної лінійної регресії використаю діаграму розподілу.


```
# Напишіть ваш код нижче та натисніть Shift+Enter для виконання
Y_hat3 = lm3.predict(x3)
plt.figure(figsize=(width, height))

sns.kdeplot(y3.squeeze(), color="r", label="Actual Value")
sns.kdeplot(Y_hat3.squeeze(), color="b", label="Fitted Values")

plt.title("Actual vs Fitted Values for CO2 Emission")
plt.xlabel("CO2 Emission")
```

```
plt.ylabel("Proportion of Area and Population")
plt.legend()
```

```
<matplotlib.legend.Legend at 0x7f3a52710980>
```




Для візуалізації поліноміальних моделей з одним предиктором використаю функцію `poly1d`. Зручно розміщувати всі моделі на одному графіку для обрання найкращої.


```
# Напишіть ваш код нижче та натисніть Shift+Enter для виконання
x_values = np.linspace(min(x4), max(x4), 100)
y_values = p4(x_values)
plt.figure(figsize=(width, height))
plt.scatter(x4, y4, label='Data')
plt.plot(x_values, y_values, color='red', label='Polynomial model')
plt.xlabel('Population')
plt.ylabel('CO2 emission')
plt.title('Polynomial regression')
```

```
plt.legend()

x_values = np.linspace(min(x5), max(x5), 100)
y_values = p5(x_values)
plt.figure(figsize=(width, height))
plt.scatter(x5, y5, label='Data')
plt.plot(x_values, y_values, color='red', label='Polynomial model')
plt.xlabel('Area')
plt.ylabel('CO2 emission')
plt.title('Polynomial regression')
plt.legend()
```

<matplotlib.legend.Legend at 0x7f3a52713620>






Для візуалізації поліноміальних моделей з кількома предикторами використаю діаграму розподілу або діаграму залишків

```
# Напишіть ваш код нижче та натисніть Shift+Enter для виконання
y_pred = pipe6.predict(x6)
residuals_df = pd.DataFrame({'Residuals': y6 - y_pred, 'Predicted':
y_pred})
plt.figure(figsize=(width, height))
sns.residplot(x=residuals_df['Predicted'],
y=residuals_df['Residuals'])
plt.title('Residuals Plot')

Text(0.5, 1.0, 'Residuals Plot')
```



Завдання #5:

Значення R^2 отримую безпосередньо з моделі `.score(X, Y)`, а для розрахунку MSE спочатку формулю прогнозовані значення `.predict(X)` і порівнюю їх з фактичними

Модель 1:

$$\hat{Y}_1 = a + bX$$

```
# Напишіть ваш код нижче та натисніть Shift+Enter для виконання
from sklearn.metrics import r2_score, mean_squared_error
r2 = lm1.score(x1, y1)
print("R-squared for Population model: ", r2)
Yhat = lm1.predict(x1)
mse = mean_squared_error(y1, Yhat)
print("Mean Squared Error for Population model: ", mse)
```

R-squared for Population model: 0.6465810146980645
Mean Squared Error for Population model: 231214423278.44647

Модель 2:

$$\hat{Y}_2 = a + bX$$

```
# Напишіть ваш код нижче та натисніть Shift+Enter для виконання
r2 = lm2.score(x2, y2)
print("R-squared for Population model: ", r2)
Yhat2 = lm2.predict(x2)
mse = mean_squared_error(y2, Yhat2)
print("Mean Squared Error for Population model: ", mse)
```

R-squared for Population model: 0.3461014134665431
Mean Squared Error for Population model: 427794744639.3072

Модель 3:

$$\hat{Y}_3 = a + b_1X_1 + b_2X_2$$

```
# Напишіть ваш код нижче та натисніть Shift+Enter для виконання
r3 = lm3.score(x3, y3)
print("R-squared for Population and Area model: ", r3)
Yhat3 = lm3.predict(x3)
mse = mean_squared_error(y3, Yhat3)
print("Mean Squared Error for Population and Area model: ", mse)
```

R-squared for Population and Area model: 0.7094563960895298
Mean Squared Error for Population and Area model: 190079974786.8917

Модель 4:

$$\hat{Y}_4 = a + b_1X_1 + b_2X_1^2$$

```
r2 = r2_score(y4, p4(x4))
print("R-squared for Population and Area model: ", r2)
mse = mean_squared_error(y4, p4(x4))
print("Mean Squared Error for Population and Area model: ", mse)
```

R-squared for Population and Area model: 0.6470968295711803
Mean Squared Error for Population and Area model: 230876965916.60153

Модель 5:

$$\hat{Y}_5 = a + b_1X_2 + b_2X_2^2$$

```
# Напишіть ваш код нижче та натисніть Shift+Enter для виконання
r2 = r2_score(y5, p5(x5))
```

```
print("R-squared for Population and Area model: ", r2)
mse = mean_squared_error(y5, p5(x5))
print("Mean Squared Error for Population and Area model: ", mse)
```

R-squared for Population and Area model: 0.3743860417036333
Mean Squared Error for Population and Area model: 409290322756.32056

Модель 6:

$$\hat{Y}_6 = a + b_1 X_1 + b_2 X_2 + b_3 X_1 X_2 + b_4 X_1^2 + b_5 X_2^2$$

```
# Напишіть ваш код нижче та натисніть Shift+Enter для виконання
r2 = pipe6.score(x6, y6)
print("R-squared: ", r2)
Yhat6 = pipe6.predict(x6)
mse = mean_squared_error(y6, Yhat6)
print("Mean Squared Error: ", mse)
```

R-squared: 0.9380434208190209
Mean Squared Error: 40533348007.31493

Додаткове завдання:

1. Побудуйте кілька поліноміальних моделей різних порядків.
2. Побудуйте візуалізації для оцінки всіх моделей, починаючи з лінійної (зручно розміщувати всі моделі на одному графіку для обрання найкращої).
3. Порахуйте значення R² та MSE для оцінки якості кожної моделі (теж доцільно побудувати графік залежності R² або MSE від порядку поліному моделі).
4. Оберіть найкращу модель, висновок обґрунтуйте.

```
X = df[['Population', 'Area']]
Y = df['CO2 emission']
degrees = range(1, 16)

r2_list = []
mse_list = []

plt.figure(figsize=(15, 25))

best_r2 = 0
best_degree = 0

for i, degree in enumerate(degrees):
    pipeline = Pipeline([
        ('scale', StandardScaler()),
        ('polynomial_features', PolynomialFeatures(degree=degree)),
        ('linear_regression', LinearRegression())
    ])
    r2_list.append(pipeline.score(X, Y))
    mse_list.append(mean_squared_error(Y, pipeline.predict(X)))

    if r2_list[i] > best_r2:
        best_r2 = r2_list[i]
        best_degree = degree + 1
```

```

pipeline.fit(X, Y)
y_pred = pipeline.predict(X)

r2 = r2_score(Y, y_pred)
mse = mean_squared_error(Y, y_pred)

r2_list.append(r2)
mse_list.append(mse)

plt.subplot(len(degrees) // 2 + 1, 2, i + 1)
sns.residplot(x=y_pred, y=Y - y_pred)
plt.title(f'Degree {degree} (R^2={r2:.4f})')
plt.xlabel('Fitted values')
plt.ylabel('Residuals')

if r2 > best_r2:
    best_r2 = r2
    best_degree = degree

plt.tight_layout()
plt.show()

fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(16, 5))


ax1.plot(degrees, r2_list, marker='o', linestyle='--', color='g')
ax1.set_title('Залежність  $R^2$  від ступеня полінома')
ax1.set_xlabel('Ступінь (Degree)')
ax1.set_ylabel(' $R^2$  Score')
ax1.grid(True)
ax1.axvline(x=best_degree, color='r', linestyle='--', label=f'Max  $R^2$  (deg {best_degree})')
ax1.legend()



ax2.plot(degrees, mse_list, marker='s', linestyle='--', color='r')
ax2.set_title('Залежність  $MSE$  від ступеня полінома')
ax2.set_xlabel('Ступінь (Degree)')
ax2.set_ylabel('Mean Squared Error')
ax2.grid(True)
ax2.set_yscale('log')
ax2.legend(['MSE'])

plt.tight_layout()
plt.show()

print(f"Best degree за показником R2: {best_degree}")
print(f"Best R2: {best_r2:.4f}")
print(f"Best MSE: {mse_list[best_degree - 1]:.4f}")

```



Best degree за показником R^2 : 9

Best R^2 : 0.9968

Best MSE: 2061590246.8757

За результатами аналізу можна побачити, що найкращою моделлю є дев'ята, оскільки має найбільший R^2 (0.997) та найменшу MSE. Отже близько 99.7% варіацій викидів CO2 пояснюються цією моделлю